

Optimización del problema de localización de puntos de pick-up mediante microhubs temporales (TMLPA) utilizando el Algoritmo de la Morsa Binario

Jorge Quiroz Hernández^{a,*}

^aEscuela de Ingeniería Informática, Universidad de Valparaíso, Chile.

Abstract

La logística de transporte urbano de carga enfrenta importantes cuellos de botella operativos durante las horas de mayor demanda, lo que exige paradigmas de distribución más flexibles. Este estudio evalúa el Problema de Localización y Asignación de Microhubs de Dos Escalones (TMLPA) con el objetivo de minimizar los costos fijos de instalación, los costos de procesamiento y las distancias de caminata. Se introduce el Algoritmo de la Morsa Binario (BWO) con mecánicas de explotación multimodales, evaluando su rendimiento frente a una línea base de Optimización por Enjambre de Partículas Binario (BPSO) y los límites exactos de Programación Lineal Entera Mixta (MILP) resueltos mediante el motor HiGHS. A lo largo de 30 ejecuciones independientes, se identificaron los valores atípicos mediante filtros estadísticos y se reemplazaron en tiempo real para garantizar la integridad de las muestras. En escalas pequeñas (3 hubs, 5 clientes), ambas metaheurísticas alcanzaron una precisión del 100 %, igualando el óptimo global exacto de 84,2000. En matrices medianas (10 hubs, 25 clientes), BPSO convergió prematuramente a un pozo local de 461,0000 (+1,99 % de brecha) debido a una pérdida total de diversidad, mientras que BWO preservó la varianza exploratoria, alcanzando un mejor valor de 464,8000 (+2,83 % de brecha). En la escala más grande (20 hubs, 50 clientes), BPSO logró acercarse al límite global (915,2000) con un costo mínimo de 920,3000 (+0,56 % de brecha), mientras que BWO equilibró un rango de búsqueda más amplio alcanzando los 933,1000 (+1,96 % de brecha). Las pruebas no paramétricas de Mann-Whitney-Wilcoxon confirmaron diferencias significativas en la distribución ($p < 0,0001$) en escalas medianas y grandes, mapeando los límites explícitos para el despliegue de heurísticas en topografías de asignación no lineales.

Keywords: Logística de última milla, Localización y asignación de microhubs, Algoritmo de la morsa binario, Optimización por enjambre de partículas, Estadística no paramétrica, Verificación de límites exactos

1. Introducción

La expansión exponencial del comercio por internet ha puesto mucha presión sobre la infraestructura para las entregas de última milla en ambientes metropolitanos. Envíos directo al consumidor generan aumento de la congestión vehicular, emisión de gases de carbono y dificultad para planear las rutas de entrega. Para mitigar estos problemas urbanos, pequeños puntos de entrega temporales (microhubs) han emergido como una alternativa eficiente y descentralizada. Estos puntos funcionan como centros de entrega locales donde una mayor cantidad de paquetes pueden ser consolidados, permitiendo a los transportistas entregar los envíos en lotes, traspasando la última parte del trayecto al consumidor.

La optimización de estos sistemas requiere resolver dos problemas simultáneamente: identificar cuáles puntos de entrega potenciales se deben habilitar desde una cantidad determinada de espacios, y asignar al consumidor a los puntos activos mientras que se respetan las restricciones operacionales. Esta ejercicio es denominado Problema de Localización-Asignación en Dos Escalones (Two-Echelon Microhub Location-Allocation

Problem o TMLPA). El objetivo principal es minimizar una matriz no lineal de gastos globales que contabiliza costos fijos de habilitación, tarifas de procesamiento dependientes de la demanda y costos de satisfacción del consumidor ponderado por valores priorizados.

Mientras que soluciones matemáticas determinísticas, como la programación lineal entera mixta (MILP, por sus siglas en inglés) pueden identificar soluciones globales exactas en configuraciones acotadas, sus tiempos de ejecución escalan exponencialmente con el número de puntos de entrega y de consumidores. Este cuello de botella computacional hace que este tipo de soluciones sean imprácticas para realizar ajustes en tiempo real o planificación en topografías urbanas de mayor escala. Consecuentemente, los enjambres metaheurísticos bioinspirados se han convertido en la estrategia dominante para navegar estos espacios de búsqueda no lineal [1].

Este estudio, implementa un marco de evaluación competitivo para resolver este desafío. Las contribuciones principales de este trabajo son:

1. Se introduce una formulación binaria del Algoritmo de Optimización de la Morsa (Binary Walrus Optimizer, BWO) [2] para resolver las restricciones de ubicación y asignación del TMLPA.
2. Se realizan pruebas de rendimiento contra una implemen-

*Corresponding author

Email address: jorge.quirozh@postgrado.uv.cl (Jorge Quiroz Hernández)

tación de referencia de Optimización por Enjambre de Partículas Binario (BPSO) sobre tres distintas escalas de magnitud. (3×5 , 10×25 , and 20×50).

3. Se establecen métricas de verdad absoluta empírica para todas las comparaciones, mediante el motor HiGHS MILP dentro de una ejecución en plataforma MiniZinc [3].
4. Se aplican filtros de calidad estadística explícitos durante la recolección de datos ($N = 30$), identificando, removiendo y re-ejecutando dinámicamente valores atípicos para preservar el tamaño de la muestra y la validez de las inferencias no paramétricas posteriores.

El resto de este artículo se organiza de la siguiente manera: Sección 2 formaliza el modelo matemático del TMLPA. Sección 3 detalla las adaptaciones discretas de los modelos BPSO y BWO. Sección 4 detalla los parámetros experimentales y protocolo de manejo de valores atípicos. Sección 5 presenta métricas cuantitativas, valoraciones estadísticas y análisis de convergencia mediante gráficos. Sección 6 analiza las compensaciones conductuales entre exploración y explotación antes de concluir en Sección 7.

2. Formulación del Modelo Matemático

El TMLPA es modelado sobre una topografía optimizada consistente de un conjunto discreto de clientes a pie $C = \{1, 2, \dots, n\}$ y un conjunto de potenciales puntos de entrega temporales $J = \{1, 2, \dots, m\}$. Cada cliente $c \in C$ presenta un volumen escalar fijo de demanda logística q_c y una priorización de servicio ponderada asociada $w_c > 0$. Las distancias especiales entre las entidades como una matriz estática d_{cj} , representando la distancia a pie desde el cliente c al punto de entrega candidato j .

Cada punto de entrega candidato $j \in J$ es limitado por una capacidad volumétrica límite L_j , una tarifa fija de habilitación f_j , y un factor de costo variable o_j representando el costo operacional por cada unidad de demanda procesada. La distancia máxima permisible de tránsito a pie de los consumidores está limitada por el valor global $D_{\max}$. Adicionalmente, el sistema aplica un estricto límite de presupuesto P , requiriendo que el número total de puntos habilitados se encuentre dentro del intervalo $[P_{\min}, P]$.

Siendo $y_j \in \{0, 1\}$ la variable de decisión binaria indicando si el punto de entrega j está activado ($y_j = 1$) permanece cerrado ($y_j = 0$). La variable $x_{cj} \in \{0, 1\}$ corresponde a la asignación, indicando si el cliente c se encuentra asignado al punto j ($x_{cj} = 1$) o no ($x_{cj} = 0$). El marco de optimización matemática se estructura de la siguiente manera:

$$\min_{x,y} Z = \sum_{j \in J} f_j y_j + \sum_{j \in J} \sum_{c \in C} o_j q_c x_{cj} + \sum_{c \in C} \sum_{j \in J} w_c d_{cj} x_{cj} \quad (1)$$

Sujeto a las siguientes restricciones sistemáticas:

$$\sum_{j \in J} x_{cj} = 1, \quad \forall c \in C \quad (2)$$

$$x_{cj} \leq y_j, \quad \forall c \in C, \forall j \in J \quad (3)$$

$$\sum_{c \in C} q_c x_{cj} \leq L_j y_j, \quad \forall j \in J \quad (4)$$

$$d_{cj} x_{cj} \leq D_{\max}, \quad \forall c \in C, \forall j \in J \quad (5)$$

$$P_{\min} \leq \sum_{j \in J} y_j \leq P \quad (6)$$

$$x_{cj}, y_j \in \{0, 1\}, \quad \forall c \in C, \forall j \in J \quad (7)$$

La ecuación (1) define la función de objetivo global, que minimiza tres componentes: costos fijos de activación global, costos variables de procesamiento de demanda, y las distancias (con priorización ponderada) que los clientes deben caminar hacia los puntos de entrega. La restricción (2) asegura que el cliente es asignado a exactamente un punto de entrega. La restricción (3) fuerza que un cliente solo pueda ser asignado a un punto de entrega si este punto ha sido seleccionado para su habilitación.

Restricción (4) previene que la demanda total asignada a un punto de entrega exceda su límite de capacidad L_j . La restricción (5) asegura los límites de accesibilidad especial $D_{\max}$ para la seguridad y comodidad de los clientes. La restricción (6) acota el número total de hubs abiertos dentro de los umbrales de asignación de recursos $[P_{\min}, P]$, mientras que la restricción (7) restringe el espacio de decisión a valores binarios.

3. Marcos Metaheurísticos

3.1. Optimización por Enjambre de Partículas Binario (BPSO)

La optimización base de enjambre usa una formulación discreta modificada del algoritmo estándar de Optimización por Enjambre de Partículas [1]. Cada partícula i dentro de un entorno de velocidad constante mantiene referencia de su vector de posición actual x_i , mejor coordenada personal histórica p_i^* , y mejor coordenada global del vecindario g^* . Para mapear los ajustes continuos a las matrices binarias discretas requeridas por las ecuaciones (7), se aplica una función de mapeo signoídeo estándar. Las actualizaciones estructurales para la velocidad $v_{i,j}^{t+1}$ y estado binario $x_{i,j}^{t+1}$ entre cada iteración t se calculan como se describe a continuación:

$$v_{i,j}^{t+1} = \theta v_{i,j}^t + \alpha \epsilon_1 (g_j^* - x_{i,j}^t) + \beta \epsilon_2 (p_{i,j}^* - x_{i,j}^t) \quad (8)$$

$$S(v_{i,j}^{t+1}) = \frac{1}{1 + \exp(-v_{i,j}^{t+1})} \quad (9)$$

$$x_{i,j}^{t+1} = \begin{cases} 1, & \text{si } r_{i,j} < S(v_{i,j}^{t+1}) \\ 0, & \text{sino} \end{cases} \quad (10)$$

donde $\theta = 0,7$ representa el coeficiente estático del momento, $\alpha = 1,7$ y $\beta = 1,7$ son los parámetros de aceleración, y $\epsilon_1, \epsilon_2, r_{i,j} \sim \mathcal{U}(0, 1)$ representan variables aleatorias independientes uniformemente distribuidas.

3.2. Algoritmo de Optimización Binario de la Morsa (BWO)

El Optimizador Binario de la Morsa propuesto imita los comportamientos biológicos de los grupos de morsas, incluyendo migración, seguimiento de seguridad y maniobras de combate agresivas [2]. Siendo $X_{i,j}^t$ la coordenada multidimensional de búsqueda del agente i durante la iteración t . Los ajustes de posición son gobernados por tres estados primarios de comportamiento, dictados por un factor de balance adaptativo β_t :

$$X_{i,j}^{t+1} = \begin{cases} X_{i,j}^t + \alpha \cdot (X_{\text{target},j} - X_{i,j}^t), & \text{Migración} \\ X_{i,j}^t + \beta_t \cdot \gamma \cdot (X_{\text{best},j} - X_{i,j}^t), & \text{Protección} \\ X_{i,j}^t - \delta \cdot |X_{\text{combat},j} - X_{i,j}^t|, & \text{Combate} \end{cases} \quad (11)$$

Para cumplir con los requisitos discretos de las restricciones de ubicación de TMLPA, los vectores de ubicación continuos se mapean a un dominio binario utilizando una función de transformación hiperbólica algebraica.:

$$T(X_{i,j}^{t+1}) = \left| \tanh(X_{i,j}^{t+1}) \right| \quad (12)$$

$$X_{\text{binario},i,j}^{t+1} = \begin{cases} 1, & \text{si } \rho_{i,j} < T(X_{i,j}^{t+1}) \\ 0, & \text{sino} \end{cases} \quad (13)$$

donde $\rho_{i,j} \sim \mathcal{U}(0, 1)$ actúa como parámetro umbral de exploración estocástica.

3.3. Motor de Aplicación de Restricciones

Para garantizar la factibilidad estructural desde las restricciones (2) hasta (5), ambos algoritmos interactúan con un módulo automatizado de asignación ávida. Cuando una partícula metaheurística actualiza su vector de posición, cambia la matriz de activación del punto de entrega y . Si la configuración del punto de entrega activo traspasa los límites presupuestarios $[P_{\min}, P]$, una heurística de reparación modifica aleatoriamente los bits de la instalación hasta que el vector sea válido.

Una vez que una matriz válida de activación de un punto de entrega y es establecida, cada cliente $c \in C$ es asignado a su punto de entrega más cercano que cumpla tanto con el límite de distancia $D_{\max}$ y la restricción de capacidad máxima L_j . Si un cliente dado no puede ser asignado válidamente debido a la capacidad o distancia, todo el vector de configuración del punto de entrega y es penalizado con un multiplicador de costo máximo (10^6), forzando al enjambre a rechazar regiones de búsqueda infactibles.

4. Configuración Experimental

El perfil empírico de ambas metaheurísticas se evaluó en tres instancias de referencia, que representan distintos niveles de escala urbana:

- **Escala Pequeña** (`instance_small.dzn`): 3×5 clientes.
- **Escala Mediana** (`instance_medium.dzn`): 10×25 clientes.

- **Escala Grande** (`instance_large.dzn`): 20×50 clientes.

Para aislar el comportamiento estocástico de la metaheurística, cada algoritmo fue ejecutado en 30 iteraciones independientes utilizando semillas aleatorias distintas y aisladas que abarcaban el intervalo de enteros [43, 72]. El tamaño de la población para cada enjambre fue fijado en 30 agentes, rastreando sus trayectorias a lo largo de una profundidad generacional de 100 ocurrencias por iteración independiente.

Para proteger la integridad de los datos, un filtro dinámico de manejo de valores atípicos fue ejecutado en los límites de cada bloque de ejecución. Luego de completar una instancia de 30 iteraciones, se calculó el Rango Intercuartil (IQR) de los costos objetivos. Cualquier ejecución que resulte en un valor fuera del límite $[Q_1 - 1,5 \times \text{IQR}, Q_3 + 1,5 \times \text{IQR}]$ se clasifica como un valor atípico estadístico. Estos valores fueron removidos del conjunto de datos y ejecutados nuevamente bajo una semilla independiente nueva, manteniendo un tamaño de muestra estable de $N = 30$ ejecuciones válidas para el análisis estadístico posterior.

Se certificaron límites globales reales mediante rutinas de cómputo paralelizadas de tipo branch and cut (ramificación y corte) Mixed-Integer Linear Programming (MILP) mediante el motor HiGHS dentro de una interfaz de línea de comandos de MiniZinc [3]. Para reducir el tiempo de espera, todos los cálculos fueron desarrollados en un servidor Dell PowerEdge T140 con un procesador Intel Xeon E-2124 processor con frecuencia de 3.30 GHz y 20 GB de memoria RAM DDR4.

5. Análisis de Resultados Empíricos

5.1. Matriz de Rendimiento Cuantitativo

El resumen estadístico de todas las instancias se encuentra compilado en la tabla 1. Además se determinó como Brecha de Optimización el porcentaje de desviación del mejor resultado de cada algoritmo sobre el valor base exacto determinado mediante el motor HiGHS MILP.

En la configuración a pequeña escala (`instance_small.dzn`), ambos algoritmos demostraron absoluta estabilidad estructural. El módulo de asignación ávida manejó efectivamente este espacio de búsqueda reducido, permitiendo que ambos enjambres encuentren el óptimo global exacto de 84,2000 en cada ejecución. Esto resultó en tasas de éxito perfectas ($\text{SRate} = 1,0000$), velocidades idénticas ($\text{SSpeed} = 1,0100$), y cero variabilidad ($\sigma = 0,0000$). El vector de disposición estructural encontrado coincide con el plano exacto real. $y = [1, 0, 1]$.

En el problema a escala mediana (`instance_medium.dzn`), el mínimo global matemático se estableció en 452,0000 por el modelo HiGHS branch-and-cut ($y = [1, 1, 1, 0, 0, 0, 1, 0, 0, 1]$). Ninguna de las metaheurísticas encontró este objetivo global debido a un mínimo local multimodal engañoso de 461,0000. BPSO exhibe convergencia prematura con todas las 30 ejecuciones atrapando al enjambre en esta meseta de costos local ($\mu = 461,0000$, $\sigma = 0,0000$), resultando en una brecha de optimización de +1,99 % ($y = [1, 1, 1, 0, 1, 0, 0, 0, 0, 1]$).

Tabla 1: Matriz de Rendimiento Consolidada: Metaheurísticas vs. Límites HiGHS Exactos

Instancia	Motor/Algoritmo	Mejor Costo	Peor Costo	μ^1	σ^2	SRate ³	SSpeed ⁴	Outliers ⁵
Pequeño (3 Hubs / 5 Clients)	Límite real HiGHS	84.2000	—	—	—	—	—	—
	Binary PSO Baseline	84.2000	84.2000	84.2000	0.0000	1.0000	1.0100	0
	Binary Walrus (Proposed)	84.2000	84.2000	84.2000	0.0000	1.0000	1.0100	0
Mediano (10 Hubs / 25 Clients)	Límite real HiGHS	452.0000	—	—	—	—	—	—
	Binary PSO Baseline	461.0000	461.0000	461.0000	0.0000	0.0000	0.0000	0
	Binary Walrus (Proposed)	464.8000	473.5000	468.9767	2.5127	0.0000	0.0000	2
Grande (20 Hubs / 50 Clients)	Límite real HiGHS	915.2000	—	—	—	—	—	—
	Binary PSO Baseline	920.3000	946.9000	930.6000	7.8947	0.0000	0.0000	0
	Binary Walrus (Proposed)	933.1000	1076.4000	1006.1533	34.2454	0.0000	0.0000	0

¹ μ : Costo promedio de la función objetivo calculado sobre exactamente $N = 30$ ejecuciones independientes.

² σ : Desviación estándar muestral; mide la dispersión del enjambre y el nivel de exploración.

³ **SRate** (*Success Rate*): Tasa de éxito. Proporción de ejecuciones que alcanzaron la solución óptima exacta global.

⁴ **SSpeed** (*Search Speed*): Velocidad de búsqueda; métrica de tiempo de convergencia generacional normalizado.

⁵ **Outliers**: Cantidad de ejecuciones anómalas detectadas por el filtro estadístico IQR y reemplazadas en caliente.

En contraste, el Optimizador de la Morsa propuesto mantuvo su comportamiento de búsqueda exploratorio, evitando un estancamiento temprano ($\sigma = 2,5127$). Alcanzó un mejor costo de configuración de 464,8000 (brecha de optimización +2,83 %) y tuvo un perfil de rendimiento promedio de 468,9767. Durante éstas ejecuciones a escala media, el filtro de valores atípicos fue gatillado dos veces, removiendo dos puntos de datos anómalos y reemplazándolos con ejecuciones independientes válidas para proteger la integridad de la muestra.

En la configuración a mayor escala (`instance_large.dzn`), el límite global exacto se verificó en 915,2000 ($y = [0, 1, 1, 0, 0, 0, 1, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0]$). El algoritmo base BPSO convergió estrechamente alrededor del piso global, logrando un costo mínimo de 920,3000, una brecha de optimización de solo +0,56 %. Sus ejecuciones permanecieron agrupadas estrechamente, evidenciado por la desviación estándar 7,8947 y costo medio de 930,6000.

El algoritmo propuesto BWO exhibió una distribución exploratorio significativamente mayor dentro del universo aumentado de esta instancia ($\sigma = 34,2454$), convergiendo en una mejor solución de 933,1000 (+1,96 % brecha de optimización) y un costo promedio de 1006,1533. No se manifestaron valores atípicos ni se requirieron reemplazos durante las ejecuciones a mayor escala.

5.2. Inferencias no paramétricas

Debido a que las soluciones obtenidas por los algoritmos estocásticos no garantizan una distribución normal, de acuerdo con la metodología propuesta por Derrac et al. [4], se aplicó la prueba no paramétrica bilateral de Mann-Whitney-Wilcoxon para evaluar la significancia estadística de las diferencias de rendimiento observadas entre BPSO y el algoritmo BWO propuesto. Las métricas estadísticas resultantes para cada escala del problema se resumen en la Tabla 2.

Los resultados de la prueba confirman diferentes comportamientos estructurales entre las magnitudes de las instancias:

- Para la instancia pequeña, el p -value de 1,00000 indica que no existe una diferencia estadística, confirmando que

 Tabla 2: Métricas prueba de hipótesis de Mann-Whitney-Wilcoxon ($N = 30$)

Magnitud Instancia	U-Statistic	p -value
Pequeño (3×5)	450.00	1.00000
Mediano (10×25)	0.00	0.00000
Grande (20×50)	10.50	0.00000

ambos enjambres convergieron hacia perfiles globales determinísticos idénticos.

- En la magnitud media, el U -statistic bajó a 0,00, causando un p -value asintótico de 0,00000. Esto confirma un cambio estadístico altamente significativo causado por el estancamiento completo de BPSO en 461,0000 comparado con la distribución más amplia de BWO.
- Para la escala mayor, la prueba arrojó un U -statistic de 10,50 y un p -value de 0,00000. Esto indica que la proximidad superior de BPSO al límite global es estadísticamente significativa, mostrando una divergencia clara en el rendimiento entre ambos algoritmos a mayor escala.

5.3. Trayectorias de convergencia y dispersión visual




Figura 1: Perfiles de trayectoria y métricas de dispersión de diagramas de caja para la instancia pequeña (3×5), que ilustran rutas de optimización idénticas y una convergencia perfecta al límite global.

Los registros visuales para la instancia pequeña (Figura 1) muestran trayectorias de optimización idénticas. Ambos algoritmos convergen rápidamente al óptimo matemático exacto en las iteraciones iniciales, manteniendo una varianza cero en todas las generaciones posteriores.




Figura 2: Perfiles de trayectoria y métricas de dispersión de diagramas de caja para la instancia media (10×25). BPSO muestra estancamiento, mientras que BWO mantiene una varianza exploratoria.

Para la magnitud media (Figura 2), los gráficos de convergencia muestran la vulnerabilidad de BPSO al estancamiento prematuro, quedando una línea plana rápidamente en 461,0000, mostrando una completa pérdida de diversidad de población. Mientras que la trayectoria de BWO muestra una exploración estructural activa, con una distribución más amplia entre las generaciones.




Figura 3: perfiles de trayectoria y métricas de dispersión de diagramas de caja para la instancia mayor (20×50), mostrando la explotación local efectiva de BPSO y la exploración extendida de BWO

En la magnitud mayor (Figura 3), las curvas de convergencia muestran que BPSO efectivamente aprovecha su mecánica de explotación local. Esto le permite al enjambre acercarse de manera estable al límite global, alzando una distribución estrecha cerca del piso de 920,3000. En el caso de BWO, se aprecia un camino exploratorio más extendido, manteniendo una distribución de soluciones más amplia a través del límite de 100 iteraciones.

6. Discusión y Compensaciones Algorítmicas

Los resultados del experimento muestran una clara compensación entre mecanismos de exploración y explotación entre espacios de asignación-ubicación discretos. BPSO se apoya fuertemente en la matriz de transformación sigmoidea, junto a componentes fijos de aceleración social y cognitiva. Mientras que esta estructura incrementa el riesgo de convergencia prematura

(como se evidenció en el estancamiento casi total en 461,0000 para la instancia media) provee una ventaja competitiva relevante para topografías de mayores dimensiones donde la gradiente local de explotación es importante. En la instancia mayor, esta intensa búsqueda local permitió a BPSO encontrar un conjunto solución más cercano al límite global establecido (brecha de +0,56 %).

En contraste, BWO incorpora un conjunto más diverso de fases de comportamiento, ntrast, the Binary Walrus Optimizer incorporates a more diverse set of behavioral phases, utilizing dynamic migration shifts, ajustes de defensa de seguridad, y modelado de estado de combate. Esta variabilidad arquitectural previene el colapso poblacional temprano y apoya la exploración sostenida a través de escenarios de búsqueda complejos, lo que le ayudó a envitar fácilmente el estancamiento mostrado por BPSO en la instancia media.

Sin embargo, esta alta varianza exploratoria se transforma en una desventaja bajo presupuestos iterativos más restringidos en espacios dimensionales mayores. En la instancia mayor, BWO repartió su foco de búsqueda en demasiadas capas, dejando una cantidad insuficiente de generaciones para explorar completamente regiones localizadas. Esta tasa menor de convergencia resultó en una varianza final mayor ($\sigma = 34,2454$) y una bracha de optimización mayor (+1,96 %). Estos hallazgos sugieren que BWO podría beneficiarse de un mecanismo de discretización adaptativo o acelerado para mejorar su comportamiento de explotación a medida que el enjambre se acerca a etapas generacionales posteriores.

7. Conclusión

Este estudio evaluó el Problema de Localización y Asignación de Microhubs de Dos Escalones (TMLPA) evaluando el Algoritmo de la Morsa Binario (BWO) contra una línea base de Optimización por Enjambre de Partículas Binario (BPSO) bajo límites globales exactos, resueltos mediante el motor de HiGS MILP engine. Este diseño experimental integró un módulo automatizado de reparación de restricciones e implementó un protocolo dinámico de manejo de valores atípicos para garantizar la consistencia estadística. ($N = 30$).

Los hallazgos empíricos muestran que mientras que ambas metaheurísticas fácilmente resuelven problemas a menor escala, su rendimiento diverge significativamente a medida que las dimensiones del problema escalan. BPSO demuestra una gran capacidad de explotación local a gran escala, logrando una brecha de optimización ajustada de +0,56 %, pero sigue siendo muy vulnerable a la convergencia prematura en topografías multimodales de escala media. Por el contrario, BWO destaca por preservar la diversidad de la población y evitar trampas locales tempranas, pero presenta tasas de explotación más lentas en espacios de búsqueda de alta dimensión.

Referencias

- [1] T. M. Shami, A. A. El-Saleh, M. Alswaitti, Q. Al-Tashi, M. A. Summakhieh, S. Mirjalili, *Particle swarm optimization: A comprehensive survey*, IEEE Access 10 (2022) 10031–10061. doi:10.1109/access.2022.

3142859.

URL <https://doi.org/10.1109/access.2022.3142859>

- [2] M. Han, Z. Du, K. F. Yuen, Walrus optimizer: A novel nature-inspired metaheuristic algorithm, *Expert Systems with Applications* 239 (2023) 122413. doi:<https://doi.org/10.1016/j.eswa.2023.122413>.
- [3] N. Nethercote, P. J. Stuckey, R. Becket, S. Brand, G. J. Duck, G. Tack, Minizinc: Towards a standard cp modelling language, in: *Principles and Practice of Constraint Programming–CP 2007*, Springer, 2007, pp. 529–543. doi:https://doi.org/10.1007/978-3-540-74970-7_38.
- [4] J. Derrac, S. García, D. Molina, F. Herrera, A practical tutorial on the use of nonparametric statistical tests as a methodology for comparing evolutionary and swarm intelligence algorithms, *Swarm and Evolutionary Computation* 1 (1) (2011) 3–18.